

Wprowadzenie do sztucznej inteligencji

Ćwiczenie 02 - Algorytmy genetyczne i ewolucyjne

Raport z badań

Semestr letni, rok akademicki 2025/2026

Autor: Wiktor Sosnowski Numer albumu: 348 561

Warszawa, czerwiec 2026

1. Treść zadania

Cel zadania polega na implementacji algorytmu genetycznego z mutacją, selekcją ruletkową, krzyżowaniem jednopunktowym oraz sukcesją generacyjną. Zaimplementowany algorytm ma następnie posłużyć do optymalizacji klasycznego, symetrycznego problemu komiwojażera.

Kroki do wykonania:

1. Implementacja algorytmu genetycznego.
 2. Zastosowanie algorytmu do rozwiązania problemu komiwojażera. Eksperymentalne dobranie zestawu parametrów, dla którego algorytm daje dobry wynik.
 3. Zbadanie, w jaki sposób następujące zmiany wpłyną na rezultaty osiągnięte przez algorytm:
 - zwiększenie prawdopodobieństwa mutacji,
 - zmiana sposobu selekcji na turniejową.
-

2. Interpretacja zadania

Problem komiwojażera (TSP) polega na znalezieniu najkrótszej trasy odwiedzającej każde miasto dokładnie raz i wracającej do punktu startowego. Jest to klasyczny problem optymalizacji kombinatorycznej klasy NP-trudnej.

Algorytm genetyczny naśladuje mechanizmy ewolucji biologicznej. Populacja osobników (permutacji miast) podlega kolejnym generacjom selekcji, krzyżowania i mutacji. Funkcja przystosowania jest odwrotnością długości trasy - im krótsza trasa, tym wyższe przystosowanie.

Selekcja ruletkowa przydziela każdemu osobnikowi prawdopodobieństwo wyboru proporcjonalne do jego przystosowania. Selekcja turniejowa losuje k osobników i wybiera najlepszego - parametr k kontroluje siłę presji selekcyjnej.

Krzyżowanie jednopunktowe dla permutacji: część trasy jednego rodzica (do losowo wybranego punktu) jest kopiowana do potomka, a pozostałe miasta są uzupełniane w kolejności występowania u drugiego rodzica, pomijając już umieszczone. Gwarantuje to poprawność permutacji.

Mutacja swap: z zadaniem prawdopodobieństwem zamieniane są pozycje dwóch losowo wybranych miast w trasie.

Sukcesja generacyjna oznacza, że cała populacja jest zastępowana nowym pokoleniem potomków w każdej generacji.

3. Zbiór danych

Użyto instancji berlin52 z biblioteki TSPLIB. Instancja zawiera 52 miasta o współrzędnych euklidesowych. Odległości obliczono jako odległości euklidesowe zaokrąglone do najbliższej liczby całkowitej, zgodnie ze standardem TSPLIB. Znane optymalne rozwiązanie wynosi 7542.

4. Opis implementacji

Implementacja składa się z dwóch modułów:

`tsp_utils.py` - wczytywanie plików TSPLIB, budowanie macierzy odległości, obliczanie długości trasy i funkcji przystosowania.

`genetic_algorithm.py` - klasa `GeneticAlgorithm` przyjmująca macierz odległości, rozmiar populacji, prawdopodobieństwo mutacji, liczbę generacji, metodę selekcji i rozmiar turnieju. Implementuje inicjalizację populacji losowymi permutacjami, selekcję ruletkową i turniejową, krzyżowanie jednopunktowe z naprawą permutacji, mutację swap oraz sukcesję generacyjną.


Każdy wariant parametrów był uruchamiany 25 razy z różnym ziarnem generatora (seed 0-24). Wyniki zapisano do plików `results.json` i `raw_lengths.csv`.

5. Konfiguracja bazowa (Baseline)

Parametry: `pop_size = 100`, `mutation_prob = 0,01`, `n_generations = 500`, `selection = roulette`.

Wariant	min	średnia	std	max
baseline	17876,00	20937,24	1048,06	22481,00

Uzyskane wyniki są znacznie powyżej optymalnego rozwiązania (7542), co jest oczekiwanym zachowaniem algorytmu bez elityzmu przy ograniczonej liczbie generacji. Wyniki stanowią punkt odniesienia dla kolejnych eksperymentów.




6. Eksperyment 1 - Rozmiar populacji

Stałe parametry: mutation_prob = 0,01, n_generations = 500, selection = roulette. Badany zakres: pop_size in {20, 50, 100, 200, 500, 1000, 2000}.

Wariant	min	średnia	std	max
pop_size = 20	22158,00	24580,00	956,84	26262,00
pop_size = 50	19776,00	22290,64	1080,27	25053,00
pop_size = 100	17876,00	20937,24	1048,06	22481,00
pop_size = 200	17963,00	19702,44	1001,07	21496,00
pop_size = 500	16920,00	19629,24	920,07	21084,00
pop_size = 1000	17693,00	19247,20	781,75	20612,00
pop_size = 2000	15097,00	18710,24	1080,44	20118,00

Średnia długość trasy maleje wraz ze wzrostem rozmiaru populacji - od 24580,00 dla pop_size = 20 do 18710,24 dla pop_size = 2000. Poprawa jest wyraźna w zakresie 20-200, natomiast od 500 wzwyż tempo poprawy spowalnia (różnica średnich między pop_size = 500 a 1000 wynosi 382, między 1000 a 2000 wynosi 537). Najniższe odchylenie standardowe osiągnięto dla pop_size = 1000 (781,75). Przy pop_size = 2000 odchylenie standardowe wzrasta do 1080,44 - porównywalne z mniejszymi populacjami - co wskazuje na niewystarczającą liczbę generacji do zbieżności tak dużej populacji.



Wnioski: Większy rozmiar populacji poprawia średnią jakość wyników, jednak zysk maleje przy dużych wartościach. Wzrost odchylenia standardowego przy pop_size = 2000 sugeruje, że przy stałej liczbie generacji (500) bardzo duże populacje nie zdążają się zbliżyć. Nie oznacza to, że duża populacja jest ogólnie niekorzystna - przy większej liczbie generacji efekt może być inny.


7. Eksperyment 2 - Prawdopodobieństwo mutacji

Stałe parametry: pop_size = 100, n_generations = 500, selection = roulette. Badany zakres: mutation_prob in {0,001, 0,003, 0,005, 0,007, 0,01, 0,05, 0,1, 0,3}.

Wariant	min	średnia	std	max
mutation_prob = 0,001	20871,00	22498,12	961,11	24610,00
mutation_prob = 0,003	19303,00	21660,84	1385,32	24203,00
mutation_prob = 0,005	18653,00	21823,20	1244,03	23962,00
mutation_prob = 0,007	18986,00	21403,84	1278,96	23646,00
mutation_prob = 0,01	17876,00	20937,24	1048,06	22481,00
mutation_prob = 0,05	20111,00	21446,00	799,25	23299,00
mutation_prob = 0,1	19843,00	21354,32	821,29	22897,00
mutation_prob = 0,3	19387,00	21738,32	750,77	23199,00

Najlepsza średnia długość trasy uzyskano dla mutation_prob = 0,01 (20937,24). Niższe wartości dają gorsze wyniki - przy 0,001 średnia wynosi 22498,12, co wskazuje na zbyt słabą eksplorację przestrzeni. Powyżej 0,01 średnia rośnie i stabilizuje się w przedziale 21354-21823, co sugeruje, że zbyt częsta mutacja zaburza wzorce wypracowane przez krzyżowanie. Zależność nie jest monotoniczna - w przedziale 0,001-0,01 obserwujemy

nieregularny trend z lokalnym pogorszeniem przy 0,005. Odchylenie standardowe maleje wraz ze wzrostem mutation_prob (od 961 do 751), co oznacza większą stabilność wyników kosztem gorszej średniej.




Wnioski: Dla instancji berlin52 przy podanych parametrach bazowych optymalne prawdopodobieństwo mutacji wynosi 0,01. Zbyt mała mutacja ogranicza eksplorację, zbyt duża zaburza dziedziczenie dobrych cech. Znalezione optimum jest specyficzne dla tej konfiguracji - przy innych parametrach optymalna wartość może się różnić.

8. Eksperyment 3 - Metoda selekcji

Stałe parametry: pop_size = 100, mutation_prob = 0,01, n_generations = 500. Badane warianty: selekcja ruletkowa oraz selekcja turniejowa z rozmiarem turnieju k in {2, 3, 5, 10}.

Wariant	min	średnia	std	max
roulette	17876,00	20937,24	1048,06	22481,00
turniej (k = 2)	13034,00	14443,84	949,16	16322,00
turniej (k = 3)	12028,00	13655,16	860,98	15168,00
turniej (k = 5)	11781,00	13632,20	792,04	15078,00
turniej (k = 10)	12447,00	13831,16	704,40	15659,00

Selekcja turniejowa przewyższa ruletkową we wszystkich badanych wariantach. Średnia dla roulette wynosi 20937,24, natomiast najlepszy wariant turniejowy (k = 5) osiąga średnią 13632,20 - poprawa o około 35%. Najlepszy wynik absolutny (min = 11781) również należy do k = 5. Wśród wariantów turniejowych najlepszą średnią osiągają k = 5 (13632,20) i k = 3 (13655,16) - różnica jest niewielka. Przy k = 10 średnia rośnie do 13831,16, a minimum do 12447, co wskazuje na nadmierną presję selekcyjną i utratę różnorodności populacji. Odchylenie standardowe maleje monotonicznie wraz ze wzrostem k (od 949 do 704).



Wnioski: Selekcja turniejowa daje wyraźnie lepsze wyniki niż ruletkowa dla problemu komiwojażera w badanej konfiguracji. Optymalna wartość rozmiaru turnieju leży w okolicach $k = 3-5$. Zbyt mały turniej ($k = 2$) nie wywiera wystarczającej presji selekcyjnej, zbyt duży ($k = 10$) prowadzi do przedwczesnej zbieżności.

9. Wnioski końcowe

Najlepsze parametry uzyskane w eksperymentach (przy $n_generations = 500$):

Parametr	Najlepsza badana wartość	Średnia długości trasy
pop_size	2000	18710,24
mutation_prob	0,01	20937,24
metoda selekcji	turniej $k = 5$	13632,20

Największy wpływ na jakość wyników miała zmiana metody selekcji z ruletkowej na turniejową - poprawa średniego wyniku o około 35% przy $k = 5$. Rozmiar populacji ma istotny wpływ, jednak zysk maleje przy dużych wartościach, a przy stałej liczbie generacji bardzo duże populacje wykazują wzrost wariancji. Prawdopodobieństwo mutacji ma umiarkowany wpływ z wyraźnym minimum w okolicach 0,01.

Wszystkie uzyskane wyniki są powyżej optymalnego rozwiązania instancji berlin52 (7542), co wynika z zastosowania sukcesji generacyjnej bez elityzmu oraz ograniczonej liczby generacji.