

Wprowadzenie do sztucznej inteligencji

Ćwiczenie 4 - Regresja i klasyfikacja **Typ dokumentu:** Raport z badań **Semestr:** letni 2025/2026 **Rok akademicki:** 2025/2026 **Autor:** Wiktor Sosnowski **Numer albumu:** 348 561 **Data:** 15.06.2026

Treść zadania

Cel zadania polega na implementacji drzewa decyzyjnego tworzonego algorytmem ID3 z ograniczeniem maksymalnej głębokości drzewa, jak również na stworzeniu i zbadaniu jakości klasyfikatora dla zbioru danych Tic-Tac-Toe Endgame.

Kroki do wykonania:

1. Zaimplementuj drzewo decyzyjne ID3 (z ograniczeniem jego maksymalnej głębokości).
 2. Zbadaj skuteczność działania klasyfikatora dla zbioru danych Tic-Tac-Toe Endgame, obliczając dokładność i macierz pomyłek.
-

Interpretacja zadania

Celem zadania jest implementacja algorytmu ID3 (Iterative Dichotomiser 3) służącego do budowy drzewa decyzyjnego dla problemów klasyfikacji. Algorytm wybiera w każdym węźle atrybut o najwyższym przyroście informacji (information gain), definiowanym jako różnica entropii Shannona zbioru przed i po podziale. Parametr maksymalnej głębokości drzewa ogranicza liczbę kolejnych podziałów, co pozwala kontrolować złożoność modelu i zapobiegać przeuczeniu.

Zbiór danych Tic-Tac-Toe Endgame zawiera przykładowe końcowe stany planszy kółko-krzyżyk opisane wyłącznie atrybutami kategorycznymi, co czyni go odpowiednim do zastosowania algorytmu ID3.

Zbiór danych

Zbiór danych Tic-Tac-Toe Endgame pochodzi z repozytorium UCI Machine Learning Repository. Zawiera 958 przykładów opisujących wszystkie możliwe końcowe stany planszy 3x3 w grze kółko-krzyżyk, w których gracz **x** wykonuje ruch jako pierwszy.

Każdy przykład składa się z 9 atrybutów kategorycznych odpowiadających polom planszy (wartości: **x**, **o**, **b** - puste pole) oraz etykiety klasy:

- **positive** - gracz **x** wygrał (626 przykładów)
- **negative** - gracz **x** nie wygrał (332 przykłady)

Zbiór jest nie zrównoważony - klasa **positive** stanowi około 65% przykładów.

Opis implementacji

Implementacja znajduje się w pliku `src/assignment_04/id3.py` i składa się z następujących elementów:

Funkcje pomocnicze:

- `entropy(labels)` - oblicza entropię Shannona tablicy etykiet
- `information_gain(labels, subsets)` - oblicza przyrost informacji dla danego podziału
- `accuracy(y_true, y_pred)` - oblicza dokładność klasyfikacji
- `confusion_matrix(y_true, y_pred)` - buduje macierz pomyłek

Klasa `Node` reprezentuje pojedynczy węzeł drzewa. Węzeł wewnętrzny przechowuje indeks atrybutu i słownik dzieci (wartość atrybutu -> węzeł), a liść przechowuje etykietę klasy.

Klasa `DecisionTreeID3` implementuje algorytm ID3:

- `fit(X, y)` - buduje drzewo rekurencyjnie metodą `_build`, wybierając w każdym węźle atrybut o najwyższym przyroście informacji; rekurencja kończy się, gdy wszystkie przykłady należą do jednej klasy, brak dostępnych atrybutów lub osiągnięto limit głębokości - w ostatnich dwóch przypadkach tworzony jest liść z etykietą wynikającą z głosu większości
- `predict(X)` - klasyfikuje przykład, przechodząc od korzenia do liścia według wartości atrybutów; dla wartości niewidzianych w treningu zwraca etykietę najczęściej występującą w poddrzewie

Implementacja jest uniwersalna - nie zawiera żadnych zależności od konkretnego zbioru danych.

Eksperymenty

Algorytm ID3 jest z natury deterministyczny - przy ustalonych danych treningowych buduje zawsze to samo drzewo. Źródłem losowości jest podział danych na zbiory treningowy, walidacyjny i testowy. Dlatego każda konfiguracja parametrów została przetestowana w 25 losowych podziałach (ziarna 0-24), a wyniki agregowano statystycznie.

Eksperyment 1 - wpływ maksymalnej głębokości drzewa

Stałe parametry: podział train/val/test = 70/15/15, 25 powtórzeń

Badany parametr: max_depth w zbiorze {1, 2, 3, 4, 5, 6, 7, 8, 9, None}

Dokładność na zbiorze walidacyjnym

max_depth	min	średnia	std	max
1	0,66	0,71	0,04	0,79
2	0,60	0,67	0,04	0,74
3	0,69	0,74	0,03	0,82
4	0,73	0,79	0,03	0,85
5	0,77	0,85	0,03	0,91
6	0,78	0,86	0,04	0,94
7	0,80	0,86	0,04	0,94

max_depth	min	średnia	std	max
8	0,80	0,86	0,04	0,94
9	0,80	0,86	0,04	0,94
None	0,80	0,86	0,04	0,94

Dokładność na zbiorze testowym

max_depth	min	średnia	std	max
1	0,65	0,69	0,03	0,75
2	0,61	0,68	0,03	0,73
3	0,68	0,74	0,03	0,79
4	0,70	0,78	0,04	0,86
5	0,78	0,84	0,03	0,92
6	0,79	0,86	0,03	0,90
7	0,79	0,86	0,03	0,91
8	0,79	0,86	0,03	0,91
9	0,79	0,86	0,03	0,91
None	0,79	0,86	0,03	0,91

Wykres eksperymentu 1

Wyniki na zbiorze walidacyjnym i testowym rosną wraz z głębokością do poziomu `max_depth = 7`, po czym pozostają niezmienione dla wartości 8, 9 i None. Oznacza to, że drzewo budowane na tym zbiorze danych nie przekracza głębokości 7 nawet bez ograniczeń - dalsze zwiększanie parametru nie ma już wpływu. Najniższą dokładność uzyskano dla `max_depth = 2`, ponieważ przy głębokości 1 drzewo stosuje tylko jeden podział i uzyskuje wyższy wynik niż przy 2, gdzie dodatkowy podział nie kompensuje jeszcze utraty informacji. Wzrost dokładności między `max_depth = 4` a 5 jest najwyraźniejszy (około 6 punktów procentowych na zbiorze testowym), co sugeruje, że na tym poziomie głębokości drzewo zaczyna uchwytować najistotniejsze zależności w danych.

Nie zaobserwowano objawów przeuczenia - dokładność na zbiorze testowym jest zbliżona do walidacyjnej na każdym poziomie głębokości.

Najlepsza wartość parametru: `max_depth = 7` (dalsze zwiększanie nie przynosi poprawy, mniejsze wartości dają gorsze wyniki).

Eksperyment 2 - wpływ proporcji zbioru treningowego

Stałe parametry: `max_depth = 7`, 25 powtórzeń; zbiór walidacyjny i testowy dzielą po równo pozostałą część danych

Badany parametr: train_ratio w zbiorze {0,50, 0,60, 0,70, 0,80, 0,90}

Dokładność na zbiorze testowym

train_ratio	min	średnia	std	max
0,50	0,76	0,83	0,03	0,88
0,60	0,78	0,85	0,02	0,89
0,70	0,79	0,86	0,03	0,91
0,80	0,78	0,86	0,03	0,91
0,90	0,73	0,85	0,05	0,94

 Wykres eksperymentu 2

Średnia dokładność na zbiorze testowym rośnie od train_ratio = 0,50 do 0,70, po czym utrzymuje się na tym samym poziomie dla 0,80 (0,86 w obu przypadkach). Przy train_ratio = 0,90 średnia nieznacznie spada, a odchylenie standardowe wyraźnie rośnie do 0,05 - wynik staje się niestabilny, co jest efektem małego rozmiaru zbioru testowego (tylko 10% danych, czyli około 96 przykładów). Wartość train_ratio = 0,70 osiąga tę samą średnią dokładność co 0,80, lecz przy większym zbiorze testowym (15% zamiast 10%), co daje bardziej wiarygodną ocenę jakości modelu.

Najlepsza wartość parametru: train_ratio = 0,70 - zapewnia dobry kompromis między rozmiarem zbioru treningowego a wiarygodnością oceny na zbiorze testowym.

Macierz pomyłek - najlepszy model

Parametry: max_depth = 7, train_ratio = 0,70 (val/test = 0,15/0,15), seed = 0

Dokładność na zbiorze testowym: 0,81

	Przewidziano: negative	Przewidziano: positive
Rzeczywiste: negative	36	18
Rzeczywiste: positive	10	81

 Macierz pomyłek

Model poprawnie sklasyfikował 117 z 145 przykładów w zbiorze testowym. Liczba fałszywie ujemnych (FN = 18, klasa positive sklasyfikowana jako negative) jest wyższa niż liczba fałszywie dodatnich (FP = 10, klasa negative sklasyfikowana jako positive). Wynika to ze struktury zbioru - klasa positive jest liczniejsza, dlatego model lepiej uczy się jej wzorców. Dokładność w tym konkretnym podziale (0,81) jest nieznacznie niższa od średniej z 25 powtórzeń (0,86), co mieści się w typowej zmienności wyników.

Wnioski końcowe

Parametr	Badany zakres	Najlepsza wartość
max_depth	1, 2, 3, 4, 5, 6, 7, 8, 9, None	7
train_ratio	0,50 - 0,90	0,70

Zaimplementowany algorytm ID3 osiąga średnią dokładność około 0,86 na zbiorze testowym przy optymalnych parametrach. Najważniejszym parametrem okazała się maksymalna głębokość drzewa - zbyt mała (1-4) wyraźnie obniża jakość klasyfikacji, natomiast powyżej 7 nie przynosi dalszej poprawy, ponieważ drzewo budowane na tym zbiorze nie przekracza tej głębokości. Nie zaobserwowano objawów przeuczenia - wyniki na zbiorach walidacyjnym i testowym są zbliżone na wszystkich poziomach głębokości.

Proporcja podziału danych ma mniejszy wpływ na średnią dokładność niż głębokość drzewa - różnica między najgorszym (0,50) a najlepszym (0,70) wynikiem wynosi około 3 punkty procentowe. Zbyt duży zbiór treningowy (0,90) skutkuje wzrostem niestabilności wyników z powodu małego rozmiaru zbioru testowego.