

Wprowadzenie do sztucznej inteligencji

Ćwiczenie 4 - Regresja i klasyfikacja **Typ dokumentu:** Raport z badań **Semestr:** letni 2025/2026 **Rok akademicki:** 2025/2026 **Autor:** Wiktor Sosnowski **Numer albumu:** 348 561 **Data:** 15.06.2026

Treść zadania

Cel zadania polega na implementacji drzewa decyzyjnego tworzonego algorytmem ID3 z ograniczeniem maksymalnej głębokości drzewa, jak również na stworzeniu i zbadaniu jakości klasyfikatora dla zbioru danych Tic-Tac-Toe Endgame.

Kroki do wykonania:

1. Zaimplementuj drzewo decyzyjne ID3 (z ograniczeniem jego maksymalnej głębokości).
 2. Zbadaj skuteczność działania klasyfikatora dla zbioru danych Tic-Tac-Toe Endgame, obliczając dokładność i macierz pomyłek.
-

Interpretacja zadania

Celem zadania jest implementacja algorytmu ID3 (Iterative Dichotomiser 3) służącego do budowy drzewa decyzyjnego dla problemów klasyfikacji. Algorytm wybiera w każdym węźle atrybut o najwyższym przyroście informacji (information gain), definiowanym jako różnica entropii Shannona zbioru przed i po podziale. Parametr maksymalnej głębokości drzewa ogranicza liczbę kolejnych podziałów, co pozwala kontrolować złożoność modelu i zapobiegać przeuczeniu.

Zbiór danych Tic-Tac-Toe Endgame zawiera przykładowe końcowe stany planszy kółko-krzyżyk opisane wyłącznie atrybutami kategorycznymi, co czyni go odpowiednim do zastosowania algorytmu ID3.

Zbiór danych

Zbiór danych Tic-Tac-Toe Endgame pochodzi z repozytorium UCI Machine Learning Repository. Zawiera 958 przykładów opisujących wszystkie możliwe końcowe stany planszy 3x3 w grze kółko-krzyżyk, w których gracz **x** wykonuje ruch jako pierwszy.

Każdy przykład składa się z 9 atrybutów kategorycznych odpowiadających polom planszy (wartości: **x**, **o**, **b** - puste pole) oraz etykiety klasy:

- **positive** - gracz **x** wygrał (626 przykładów)
- **negative** - gracz **x** nie wygrał (332 przykłady)

Zbiór jest nie zrównoważony - klasa **positive** stanowi około 65% przykładów.

Opis implementacji

Implementacja znajduje się w pliku `src/assignment_04/id3.py` i składa się z następujących elementów:

Funkcje pomocnicze:

- `entropy(labels)` - oblicza entropię Shannona tablicy etykiet
- `information_gain(labels, subsets)` - oblicza przyrost informacji dla danego podziału
- `accuracy(y_true, y_pred)` - oblicza dokładność klasyfikacji
- `confusion_matrix(y_true, y_pred)` - buduje macierz pomyłek

Klasa `Node` reprezentuje pojedynczy węzeł drzewa. Węzeł wewnętrzny przechowuje indeks atrybutu i słownik dzieci (wartość atrybutu -> węzeł), a liść przechowuje etykietę klasy.

Klasa `DecisionTreeID3` implementuje algorytm ID3:

- `fit(X, y)` - buduje drzewo rekurencyjnie metodą `_build`, wybierając w każdym węźle atrybut o najwyższym przyroście informacji; rekurencja kończy się, gdy wszystkie przykłady należą do jednej klasy, brak dostępnych atrybutów lub osiągnięto limit głębokości - w ostatnich dwóch przypadkach tworzony jest liść z etykietą wynikającą z głosu większości
- `predict(X)` - klasyfikuje przykład, przechodząc od korzenia do liścia według wartości atrybutów; dla wartości niewidzianych w treningu zwraca etykietę najczęściej występującą w poddrzewie

Implementacja jest uniwersalna - nie zawiera żadnych zależności od konkretnego zbioru danych.

Eksperymenty

Algorytm ID3 jest z natury deterministyczny - przy ustalonych danych treningowych buduje zawsze to samo drzewo. Źródłem losowości jest podział danych na zbiory treningowy, walidacyjny i testowy. Dlatego każda konfiguracja parametrów została przetestowana w 25 losowych podziałach (ziarna 0-24), a wyniki agregowano statystycznie.

Eksperyment 1 - wpływ maksymalnej głębokości drzewa

Stałe parametry: podział train/val/test = 70/15/15, 25 powtórzeń

Badany parametr: max_depth w zbiorze {1, 2, 3, 4, 5, 6, 7, 8, 9, None}


Dokładność na zbiorze walidacyjnym

max_depth	min	średnia	std	max
1	0,66	0,71	0,04	0,79
2	0,60	0,67	0,04	0,74
3	0,69	0,74	0,03	0,82
4	0,73	0,79	0,03	0,85
5	0,77	0,85	0,03	0,91
6	0,78	0,86	0,04	0,94
7	0,80	0,86	0,04	0,94

max_depth	min	średnia	std	max
8	0,80	0,86	0,04	0,94
9	0,80	0,86	0,04	0,94
None	0,80	0,86	0,04	0,94

Dokładność na zbiorze testowym

max_depth	min	średnia	std	max
1	0,65	0,69	0,03	0,75
2	0,61	0,68	0,03	0,73
3	0,68	0,74	0,03	0,79
4	0,70	0,78	0,04	0,86
5	0,78	0,84	0,03	0,92
6	0,79	0,86	0,03	0,90
7	0,79	0,86	0,03	0,91
8	0,79	0,86	0,03	0,91
9	0,79	0,86	0,03	0,91
None	0,79	0,86	0,03	0,91



Wyniki na zbiorze walidacyjnym i testowym rosną wraz z głębokością do poziomu max_depth = 7, po czym pozostają niezmienione dla wartości 8, 9 i None. Oznacza to, że drzewo budowane na tym zbiorze danych nie

przekracza głębokości 7 nawet bez ograniczeń - dalsze zwiększanie parametru nie ma już wpływu. Najniższą dokładność uzyskano dla `max_depth = 2`, ponieważ przy głębokości 1 drzewo stosuje tylko jeden podział i uzyskuje wyższy wynik niż przy 2, gdzie dodatkowy podział nie kompensuje jeszcze utraty informacji. Wzrost dokładności między `max_depth = 4` a 5 jest najwyraźniejszy (około 6 punktów procentowych na zbiorze testowym), co sugeruje, że na tym poziomie głębokości drzewo zaczyna wychwytywać najistotniejsze zależności w danych.

Nie zaobserwowano objawów przeuczenia - dokładność na zbiorze testowym jest zbliżona do walidacyjnej na każdym poziomie głębokości.

Najlepsza wartość parametru: `max_depth = 7` (dalsze zwiększanie nie przynosi poprawy, mniejsze wartości dają gorsze wyniki).


Eksperyment 2 - wpływ proporcji zbioru treningowego

Stałe parametry: `max_depth = 7`, 25 powtórzeń; zbiór walidacyjny i testowy dzielą po równo pozostałą część danych

Badany parametr: `train_ratio` w zbiorze {0,50, 0,60, 0,70, 0,80, 0,90}

Dokładność na zbiorze testowym

<code>train_ratio</code>	<code>min</code>	<code>średnia</code>	<code>std</code>	<code>max</code>
0,50	0,76	0,83	0,03	0,88
0,60	0,78	0,85	0,02	0,89
0,70	0,79	0,86	0,03	0,91
0,80	0,78	0,86	0,03	0,91
0,90	0,73	0,85	0,05	0,94



Średnia dokładność na zbiorze testowym rośnie od `train_ratio = 0,50` do `0,70`, po czym utrzymuje się na tym samym poziomie dla `0,80` (`0,86` w obu przypadkach). Przy `train_ratio = 0,90` średnia nieznacznie spada, a odchylenie standardowe wyraźnie rośnie do `0,05` - wynik staje się niestabilny, co jest efektem małego rozmiaru zbioru testowego (tylko 10% danych, czyli około 96 przykładów). Wartość `train_ratio = 0,70` osiąga tę samą średnią dokładność co `0,80`, lecz przy większym zbiorze testowym (15% zamiast 10%), co daje bardziej wiarygodną ocenę jakości modelu.


Najlepsza wartość parametru: `train_ratio = 0,70` - zapewnia dobry kompromis między rozmiarem zbioru treningowego a wiarygodnością oceny na zbiorze testowym.

Macierz pomyłek - najlepszy model

Parametry: `max_depth = 7`, `train_ratio = 0,70` (`val/test = 0,15/0,15`), `seed = 0`

Dokładność na zbiorze testowym: `0,81`

	Przewidziano: negative	Przewidziano: positive
Rzeczywiste: negative	36	18
Rzeczywiste: positive	10	81



Model poprawnie sklasyfikował 117 z 145 przykładów w zbiorze testowym. Liczba fałszywie ujemnych (FN = 18, klasa positive sklasyfikowana jako negative) jest wyższa niż liczba fałszywie dodatnich (FP = 10, klasa negative sklasyfikowana jako positive). Wynika to ze struktury zbioru - klasa positive jest liczniejsza, dlatego model lepiej uczy się jej wzorców. Dokładność w tym konkretnym podziale (0,81) jest nieznacznie niższa od średniej z 25 powtórzeń (0,86), co mieści się w typowej zmienności wyników.

Wnioski końcowe

Parametr	Badany zakres	Najlepsza wartość
max_depth	1, 2, 3, 4, 5, 6, 7, 8, 9, None	7
train_ratio	0,50 - 0,90	0,70

Zaimplementowany algorytm ID3 osiąga średnią dokładność około 0,86 na zbiorze testowym przy optymalnych parametrach. Najważniejszym parametrem okazała się maksymalna głębokość drzewa - zbyt mała (1-4) wyraźnie obniża jakość klasyfikacji, natomiast powyżej 7 nie przynosi dalszej poprawy, ponieważ drzewo budowane na tym zbiorze nie przekracza tej głębokości. Nie zaobserwowano objawów przeuczenia - wyniki na zbiorach walidacyjnym i testowym są zbliżone na wszystkich poziomach głębokości.

Proporcja podziału danych ma mniejszy wpływ na średnią dokładność niż głębokość drzewa - różnica między najgorszym (0,50) a najlepszym (0,70) wynikiem wynosi około 3 punkty procentowe. Zbyt duży zbiór

treningowy (0,90) skutkuje wzrostem niestabilności wyników z powodu małego rozmiaru zbioru testowego.