

Wprowadzenie do sztucznej inteligencji

Ćwiczenie 4 - Regresja i klasyfikacja **Typ dokumentu:** Raport z badan **Semestr:** letni 2025/2026 **Rok akademicki:** 2025/2026 **Autor:** Wiktor Sosnowski **Numer albumu:** 348 561 **Data:** 15.06.2026

Treszcz zadania

Cel zadania polega na implementacji drzewa decyzyjnego tworzonego algorytmem ID3 z ograniczeniem maksymalnej glebokosci drzewa, jak rowniez na stworzeniu i zbadaniu jakosci klasyfikatora dla zbioru danych Tic-Tac-Toe Endgame.

Kroki do wykonania:

1. Zaimplementuj drzewo decyzyjne ID3 (z ograniczeniem jego maksymalnej glebokosci).
 2. Zbadaj skuteczznosc dzialania klasyfikatora dla zbioru danych Tic-Tac-Toe Endgame, obliczajac dokladnosc i macierz pomylek.
-

Interpretacja zadania

Celem zadania jest implementacja algorytmu ID3 (Iterative Dichotomiser 3) sluzacego do budowy drzewa decyzyjnego dla problemow klasyfikacji. Algorytm wybiera w kazdym wezle atrybut o najwyzszym przyroscie informacji (information gain), definiowanym jako roznica entropii Shannona zbioru przed i po podziale. Parametr maksymalnej glebokosci drzewa ogranicza liczbe kolejnych podzialow, co pozwala kontrolowac zlozonosc modelu i zapobiegac przeuczeniu.

Zbior danych Tic-Tac-Toe Endgame zawiera przykladowe koncowe stany planszy kolko-krzyzyk opisane wylacznie atrybutami kategorierycznymi, co czyni go odpowiednim do zastosowania algorytmu ID3.

Zbior danych

Zbior danych Tic-Tac-Toe Endgame pochodzi z repozytorium UCI Machine Learning Repository. Zawiera 958 przykladow opisujacych wszystkie mozliwe koncowe stany planszy 3x3 w grze kolko-krzyzyk, w ktorych gracz **x** wykonuje ruch jako pierwszy.

Kazdy przyklad sklada sie z 9 atrybutow kategorierycznych odpowiadajacych polom planszy (wartosci: **x**, **o**, **b** - puste pole) oraz etykiety klasy:

- **positive** - gracz **x** wygral (626 przykladow)
- **negative** - gracz **x** nie wygral (332 przyklady)

Zbior jest niezbilansowany - klasa **positive** stanowi okolo 65% przykladow.

Opis implementacji

Implementacja znajduje sie w pliku `src/assignment_04/id3.py` i sklada sie z nastepujacych elementow:

Funkcje pomocnicze:

- `entropy(labels)` - oblicza entropie Shannona tablicy etykiet
- `information_gain(labels, subsets)` - oblicza przyrost informacji dla danego podziału
- `accuracy(y_true, y_pred)` - oblicza dokładność klasyfikacji
- `confusion_matrix(y_true, y_pred)` - buduje macierz pomyłek

Klasa `Node` reprezentuje pojedynczy węzeł drzewa. Węzeł wewnętrzny przechowuje indeks atrybutu i słownik dzieci (wartość atrybutu -> węzeł), a liść przechowuje etykiety klasy.

Klasa `DecisionTreeID3` implementuje algorytm ID3:

- `fit(X, y)` - buduje drzewo rekurencyjnie metodą `_build`, wybierając w każdym węźle atrybut o najwyższym przyroście informacji; rekurencja kończy się gdy wszystkie przykłady należą do jednej klasy, brak dostępnych atrybutów lub osiągnięto limit głębokości - w ostatnich dwóch przypadkach tworzony jest liść z etykietą wynikającą z głosu większości
- `predict(X)` - klasyfikuje przykład przechodząc od korzenia do liścia według wartości atrybutów; dla wartości niewidzianych w treningu zwraca etykiety najczęściej występujące w poddrzewie

Implementacja jest uniwersalna - nie zawiera żadnych zależności od konkretnego zbioru danych.

Eksperymenty

W każdym eksperymencie algorytm ID3 jest z natury deterministyczny - przy ustalonych danych treningowych buduje zawsze to samo drzewo. Źródłem losowości jest podział danych na zbiory treningowy, walidacyjny i testowy. Dlatego każda konfiguracja parametrów została przetestowana w 25 losowych podziałach (ziarna 0-24), a wyniki agregowano statystycznie.

Eksperyment 1 - wpływ maksymalnej głębokości drzewa

Stale parametry: podział train/val/test = 70/15/15, 25 powtórzeń

Badany parametr: `max_depth` ∈ {1, 2, 3, 4, 5, 6, 7, 8, 9, None}

Dokładność na zbiorze walidacyjnym

<code>max_depth</code>	<code>min</code>	<code>srednia</code>	<code>std</code>	<code>max</code>
1	0,66	0,71	0,04	0,79
2	0,60	0,67	0,04	0,74
3	0,69	0,74	0,03	0,82
4	0,73	0,79	0,03	0,85
5	0,77	0,85	0,03	0,91
6	0,78	0,86	0,04	0,94
7	0,80	0,86	0,04	0,94

max_depth	min	srednia	std	max
8	0,80	0,86	0,04	0,94
9	0,80	0,86	0,04	0,94
None	0,80	0,86	0,04	0,94

Dokladnosc na zbiorze testowym

max_depth	min	srednia	std	max
1	0,65	0,69	0,03	0,75
2	0,61	0,68	0,03	0,73
3	0,68	0,74	0,03	0,79
4	0,70	0,78	0,04	0,86
5	0,78	0,84	0,03	0,92
6	0,79	0,86	0,03	0,90
7	0,79	0,86	0,03	0,91
8	0,79	0,86	0,03	0,91
9	0,79	0,86	0,03	0,91
None	0,79	0,86	0,03	0,91

Wykres eksperymentu 1

Wyniki na zbiorze walidacyjnym i testowym rosną wraz z głębokością do poziomu $\text{max_depth} = 7$, po czym pozostają niezmiennicze dla wartości 8, 9 i None. Oznacza to, że drzewo budowane na tym zbiorze danych nie przekracza głębokości 7 nawet bez ograniczeń - dalsze zwiększanie parametru nie ma już wpływu. Najniższą dokładność uzyskano dla $\text{max_depth} = 2$, co jest efektem zbyt dużej redukcji przestrzeni hipotez przy jednoczesnym braku wystarczającej reprezentacji danych przy $\text{depth} = 1$. Wzrost dokładności między $\text{depth} = 4$ a 5 jest najwyraźniejszy (około 6 punktów procentowych na zbiorze testowym), co sugeruje, że na tym poziomie głębokości drzewo zaczyna uchwycić najistotniejsze zależności w danych.

Nie zaobserwowano oznaki przeuczenia - dokładność na zbiorze testowym jest zbliżona do walidacyjnej na każdym poziomie głębokości.

Najlepsza wartość parametru: $\text{max_depth} = 7$ (dalsze zwiększanie nie przynosi poprawy, mniejsze wartości dają gorsze wyniki).

Eksperyment 2 - wpływ proporcji zbioru treningowego

Stale parametry: $\text{max_depth} = 7$, 25 powtórzeń; zbiór walidacyjny i testowy dzieli po równo pozostała część danych

Badany parametr: $\text{train_ratio} \in \{0,50, 0,60, 0,70, 0,80, 0,90\}$

Dokladnosc na zbiorze testowym

train_ratio	min	srednia	std	max
0,50	0,76	0,83	0,03	0,88
0,60	0,78	0,85	0,02	0,89
0,70	0,79	0,86	0,03	0,91
0,80	0,78	0,86	0,03	0,91
0,90	0,73	0,85	0,05	0,94

Wykres eksperymentu 2

Srednia dokladnosc na zbiorze testowym rosnie od train_ratio = 0,50 do 0,70, po czym utrzymuje sie na tym samym poziomie dla 0,80 (0,8590 w obu przypadkach). Przy train_ratio = 0,90 srednia nieznacznie spada, a odchylenie standardowe wyraznie rosnie do 0,05 - wynik staje sie niestabilny, co jest efektem malego rozmiaru zbioru testowego (tylko 10% danych, czyli okolo 96 przykladow). Przy train_ratio = 0,70 model osiaga dokladnosc rowna tej dla 0,80, ale przy nizszym odchyleniu standardowym (0,03 vs 0,03 - identyczne), jednak przy wiekszym zbiorze testowym, co daje bardziej wiarygodna ocene.

Najlepsza wartosc parametru: train_ratio = 0,70 - zapewnia dobry kompromis miedzy rozmiarem zbioru treningowego a wiarygodnoscia oceny na zbiorze testowym.

Macierz pomylek - najlepszy model

Parametry: max_depth = 7, train_ratio = 0,70 (val/test = 0,15/0,15), seed = 0

Dokladnosc na zbiorze testowym: 0,8069

	Przewidziano: negative	Przewidziano: positive
Rzeczywiste: negative	36	18
Rzeczywiste: positive	10	81

Macierz pomylek

Model poprawnie sklasyfikowal 117 z 145 przykladow w zbiorze testowym. Liczba falszywie ujemnych (FN = 18, klasa positive sklasyfikowana jako negative) jest wyzsza niz falszywie dodatnich (FP = 10, klasa negative sklasyfikowana jako positive). Wynika to ze struktury zbioru - klasa positive jest liczniejsza, dlatego model lepiej uczy sie jej wzorcow. Dokladnosc w tym konkretnym podziale (0,81) jest nieznacznie nizsza od sredniej z 25 powtorzen (0,86), co miesci sie w typowej zmiennosci wynikow.

Wnioski koncowe

Parametr	Badany zakres	Najlepsza wartosc
max_depth	1, 2, 3, 4, 5, 6, 7, 8, 9, None	7

Parametr	Badany zakres	Najlepsza wartosc
train_ratio	0,50 - 0,90	0,70

Zaimplementowany algorytm ID3 osiaga srednia dokladnosc okolo 0,86 na zbiorze testowym przy optymalnych parametrach. Najwazniejszym parametrem okazala sie maksymalna glebokosci drzewa - zbyt mala (1-4) wyraznie obniza jakosc klasyfikacji, natomiast powyzej 7 nie przynosi dalszej poprawy, poniewaz drzewo budowane na tym zbiorze nie przekracza tej glebokosci. Brak objawow przeuczenia - wyniki na zbiorach walidacyjnym i testowym sa zblizone na wszystkich poziomach glebokosci.

Proporcja podzialu danych ma mniejszy wplyw na srednia dokladnosc niz glebokosci drzewa - roznica miedzy najgorszym (0,50) a najlepszym (0,70) wynikiem wynosi okolo 3 punkty procentowe. Zbyt duzy zbior treningowy (0,90) skutkuje wzrostem niestabilnosci wynikow z powodu malego rozmiaru zbioru testowego.