

Wprowadzenie do sztucznej inteligencji

Numer cwiczenia: 06

Temat: Uczenie sie ze wzmacnieniem - Q-Learning

Typ dokumentu: Raport z badan

Semestr: letni 2025/2026

Autor: Wiktor Sosnowski

Numer albumu: 348 561

Data: 15.06.2026

Tresc zadania

Cel zadania polega na implementacji algorytmu Q-learning oraz zastosowaniu go do rozwiazania problemu Cliff Walking. Srodowisko to jest dostepne w pakiecie gymnasium (`gym.make('CliffWalking-v0')`).

Kroki do wykonania:

1. Implementacja algorytmu Q-learning.
2. Zbadanie skuteczności działania algorytmu dla problemu Cliff Walking dla różnych wartości współczynnika uczenia i różnej liczby epizodów (w procesie trenowania).

Uwagi: Implementacja algorytmu powinna być uniwersalna, tzn. możliwa do wykorzystania dla różnych środowisk o dyskretnej przestrzeni stanów i akcji.

Interpretacja zadania

Q-learning jest algorytmem uczenia się ze wzmacnieniem (ang. reinforcement learning). Agent działa w środowisku, które po każdej akcji zwraca nagrodę i nowy stan. Celem agenta jest maksymalizacja sumarycznej nagrody w epizodzie.

Algorytm utrzymuje tablice Q o wymiarach liczba_stanów x liczba_akcji. Każdy wpis $Q(s, a)$ przybliża oczekiwaną sumaryczną nagrodę, jaką agent uzyska, będąc w stanie s i wykonując akcję a , a następnie postępując optymalnie. Aktualizacja po każdym kroku odbywa się według wzoru:

$$Q(s, a) \leftarrow Q(s, a) + \alpha * (r + \gamma * \max_{a'} Q(s', a') - Q(s, a))$$

gdzie α to współczynnik uczenia, γ to współczynnik dyskontowania nagród przyszłych, r to otrzymana nagroda, a s' to następny stan.

Do wyboru akcji stosowana jest strategia epsilon-zachłanna: z prawdopodobieństwem epsilon agent wybiera losową akcję (eksploracja), a z prawdopodobieństwem $1 - \epsilon$ wybiera akcję o najwyższej wartości Q (eksploatacja).

Środowisko Cliff Walking to siatka 4x12. Agent startuje w lewym dolnym rogu i musi dotrzeć do prawego dolnego rogu. Dolny rząd (oprócz startu i celu) to klif - wejście na niego kończy epizod z karą -100. Każdy krok

kosztuje -1. Optymalna sciezka prowadzi wzdluz klifu i ma dlugosc 12 krokow (nagroda -12), jednak agent uczacy sie ze wzmocnieniem - ze wzgledu na ryzyko wpadniecia na klif podczas eksploracji - typowo uczy sie bezpieczniejszej sciezki gornym skrajem siatki o dlugosci 13 krokow (nagroda -13).

Skuteczność po treningu oceniana jest jednym epizodem greedy (epsilon=0): mierzona jest suma nagrod (reward) i liczba krokow (steps).

Opis implementacji

Zaimplementowano klasę `QLearningAgent` z metoda `update` realizująca krok TD (ang. temporal difference) zgodnie z powyższym wzorem. Tablica Q inicjalizowana jest zerami. Wybór akcji realizuje metoda `select_action` z parametrem `greedy` - przy `greedy=True` agent zawsze wybiera akcje o najwyższej wartości Q (ewaluacja po treningu).

Funkcja `train` przeprowadza trening przez zadana liczbę epizodow. Funkcja `evaluate` uruchamia jeden epizod greedy z limitem 200 krokow - limit ten zapobiega nieskończonej petli dla nienauczonego agenta (nienauczony agent krąży w miejscu, ponieważ wszystkie wartości Q są równe zero i argmax zawsze zwraca akcje o indeksie 0).

Funkcja `run_experiment` powtarza pełny cykl trening+ewaluacja 25 razy z niezależną tablicą Q i innym ziarnem generatora liczb pseudolosowych w każdym uruchomieniu.

Implementacja jest uniwersalna - przyjmuje jako parametry liczbę stanow i akcji, więc może być użyty dla dowolnego środowiska o dyskretnej przestrzeni stanow i akcji.

Środowisko


Użyto środowiska `CliffWalking-v1` z pakietu `gymnasium` z domyślnym parametrem `is_slippery=False`, co jest równoważne z opisanym w treści zadania `CliffWalking-v0` (wersja v0 została wycofana w aktualnej wersji biblioteki). Środowisko ma 48 stanow (siatka 4x12) i 4 akcje (gora, prawo, dol, lewo).

Konfiguracja bazowa (Baseline)

Parametry: alpha=0,5, gamma=0,99, epsilon=0,1, num_episodes=500, n_runs=25

metryka	min	srednia	std	max
nagroda	-13,00	-13,00	0,00	-13,00
liczba krokow	13,00	13,00	0,00	13,00

Przy konfiguracji bazowej we wszystkich 25 uruchomieniach agent osiąga wynik -13 (13 krokow) - min, srednia, max i std są identyczne. Jest to oczekiwany wynik dla Q-learning w tym środowisku - agent uczy się bezpiecznej ścieżki gornym skrajem siatki, unikając klifu.



Krzywa uczenia pokazuje szybkie osiągnięcie stabilnego wyniku około -13. Wahania we wczesnych epizodach wynikają z eksploracji - agent wpada na klif, co generuje duże kary. Po około 50-100 epizodach algorytm stabilizuje się na optymalnej ścieżce.

Eksperyment 1 - wpływ współczynnika uczenia (alpha)

Stale parametry: gamma=0,99, epsilon=0,1, num_episodes=100

Badany zakres: alpha w {0,1; 0,3; 0,5; 0,7; 0,9}

Liczba epizodów ustawiona na 100, ponieważ przy tej wartości różnice między wartościami alpha są wyraźnie widoczne - więcej epizodów prowadzi do zbiegnięcia wszystkich wariantów.


Tabela 1a - nagroda ewaluacyjna vs alpha

alpha	min	srednia	std	max
0,1	-200,00	-200,00	0,00	-200,00
0,3	-200,00	-20,56	36,63	-13,00
0,5	-13,00	-13,00	0,00	-13,00
0,7	-13,00	-13,00	0,00	-13,00
0,9	-13,00	-13,00	0,00	-13,00

Tabela 1b - liczba kroków ewaluacyjnych vs alpha

alpha	min	srednia	std	max
0,1	200,00	200,00	0,00	200,00
0,3	13,00	20,56	36,63	200,00
0,5	13,00	13,00	0,00	13,00
0,7	13,00	13,00	0,00	13,00

alpha	min	srednia	std	max
0,9	13,00	13,00	0,00	13,00



Przy $\alpha=0,1$ agent w zadnym z 25 uruchomien nie zdolal nauczyć się właściwej polityki w ciągu 100 epizodów - wynik -200 odpowiada limitowi 200 kroków, co oznacza brak zbieżności. Mały współczynnik uczenia powoduje, że wartości Q aktualizowane są bardzo wolno i 100 epizodów to za mało, by zgromadzić wystarczającą wiedzę.

Przy $\alpha=0,3$ wyniki są niejednorodne: średnia -20,56 ze standardowym odchyleniem 36,63 wskazuje, że część uruchomień zbiega do optimum (-13), a część nie - co potwierdza $\max=-13$ i $\min=-200$. Współczynnik jest już wystarczający do zbieżności, ale nie w sposób pewny.

Od $\alpha=0,5$ wyżej we wszystkich 25 uruchomieniach wynik ewaluacyjny wynosi -13, a $\text{std}=0$ - brak jakiegokolwiek zmienności między uruchomieniami. Większe wartości α przyspieszają uczenie, przez co 100 epizodów jest wystarczające.

Wniosek: Zbyt mały współczynnik uczenia ($\alpha=0,1$) uniemożliwia zbieżność przy 100 epizodach - żadne z 25 uruchomień nie osiąga celu ($\text{std}=0$, $\text{mean}=-200$). Wartości α od 0,5 wzwyż dają wynik -13 we

wszystkich 25 uruchomieniach (std=0). W tym środowisku optymalny zakres to $\alpha \geq 0,5$ przy 100 epizodach treningowych.

Eksperyment 2 - wpływ liczby epizodów treningowych

Stale parametry: $\alpha=0,5$, $\gamma=0,99$, $\epsilon=0,1$


Badany zakres: num_episodes w {10; 20; 30; 50; 75; 100; 200; 500}

Tabela 2a - nagroda ewaluacyjna vs liczba epizodów

liczba epizodów	min	srednia	std	max
10	-200,00	-200,00	0,00	-200,00
20	-200,00	-200,00	0,00	-200,00
30	-200,00	-200,00	0,00	-200,00
50	-200,00	-95,28	92,82	-13,00
75	-13,00	-13,00	0,00	-13,00
100	-13,00	-13,00	0,00	-13,00
200	-13,00	-13,00	0,00	-13,00
500	-13,00	-13,00	0,00	-13,00

Tabela 2b - liczba kroków ewaluacyjnych vs liczba epizodów

liczba epizodów	min	srednia	std	max
10	200,00	200,00	0,00	200,00
20	200,00	200,00	0,00	200,00
30	200,00	200,00	0,00	200,00
50	13,00	95,28	92,82	200,00
75	13,00	13,00	0,00	13,00
100	13,00	13,00	0,00	13,00
200	13,00	13,00	0,00	13,00
500	13,00	13,00	0,00	13,00



Przy 10-30 epizodach agent nie zbiega w zadnym z 25 uruchomien - tablica Q nie zostaje wystarczajaco wypelniona, by polityka greedy prowadzila do celu. Wynik -200 oznacza osiagniecie limitu krokow.

Przy 50 epizodach widoczna jest niejednorodnosc wynikow: srednia -95,28 ze standardowym odchyleniem 92,82 wskazuje, ze czesc uruchomien osiaga optimum, a czesc nie. Jest to punkt przejscia, w ktorym zbieznosc jest mozliwa, ale niestabilna.

Od 75 epizodow agent zbiega do optymalnego wyniku -13 we wszystkich 25 uruchomieniach. Zwiekszenie liczby epizodow powyzej 75 nie poprawia juz wyniku ewaluacyjnego - algorytm osiaga optimum, ktorego nie mozna przekroczyć bez zmiany epsilon lub gamma.

Wniosek: Przy alpha=0,5 juz 75 epizodow treningowych wystarczy, by we wszystkich 25 uruchomieniach uzyskac wynik -13 (std=0). Dalsze zwiekszenie liczby epizodow nie przynosi poprawy wyniku ewaluacyjnego.

Wnioski koncowe

parametr	badany zakres	najlepsze wartosci
alpha	0,1 - 0,9	$\geq 0,5$ (przy 100 epizodach)
num_episodes	10 - 500	≥ 75 (przy alpha=0,5)

Q-learning skutecznie rozwiazuje problem Cliff Walking. Algorytm uczy sie bezpiecznej polityki gornym skrajem siatki (nagroda -13, 13 krokow), a nie optymalnej w sensie teorii (-12, 12 krokow wzdluz klifu). Jest to typowe zachowanie Q-learning: podczas eksploracji agent wpada na klif, co penalizuje sciezke krawiedzia na tyle, ze preferowana staje sie dluzsza, ale bezpieczniejsza trasa.

Wspolczynnik uczenia alpha ma istotny wplyw na szybkoosc zbieznosci. Przy alpha=0,1 zadne z 25 uruchomien nie osiaga celu w ciagu 100 epizodow. Przy alpha=0,5 i wyzej wszystkie 25 uruchomien daje identyczny wynik -13 (std=0).

Liczba epizodow treningowych wyznacza, czy agent zdazy zebrac wystarczajaca liczbe obserwacji. Przy alpha=0,5 i 10-30 epizodach zadne z 25 uruchomien nie osiaga celu. Przy 75 epizodach wszystkie 25 uruchomien daje wynik -13 (std=0) i dalsze zwiekszenie liczby epizodow nie zmienia tego wyniku.

Oba parametry wplywaja na zbieznosc w podobny sposob: niewystarczajace wartosci uniemozliwiaja nauke, a po przekroczeniu progu wynik stabilizuje sie na optimum i nie mozna go dalej poprawic przez same zwiekszenie alpha lub liczby epizodow.